


Model-First arhitektura poslovnih sustava

Preispitivanje poslovnih sustava u eri umjetne inteligencije

“Primarni artefakt poslovnog sustava trebao bi biti upravljani poslovni model - a ne aplikacijski kod izgrađen oko njega.”



Modeliraj jednom. Upravljaj eksplicitno. Interpretiraj svugdje.

Davor Veljača

Srpanj 2026.

NAPOMENA AUTORA

Strateška arhitektonska vizija

Ovaj dokument razmatra moguću evoluciju poslovnih informacijskih sustava u trenutku kada umjetna inteligencija može interpretirati formalni i upravljani poslovni model.

Nije riječ o tehničkoj specifikaciji jedne aplikacije niti o rješenju vezanom uz jednog AI dobavljača, jednog cloud pružatelja ili jednu tehnologiju korisničkog sučelja. Središnja ideja namjerno je tehnološki neutralna: trajno poslovno značenje treba pripadati organizaciji, dok tehnologije koje ga interpretiraju trebaju ostati zamjenjive.

DEPRO se kasnije koristi kao studija slučaja kako bi se koncept učinio konkretnim i pokazalo kako bi mogao utjecati na svakodnevni rad, regulatorne promjene, revizijsku sljedivost, razvojne uloge i infrastrukturnu strategiju.

PREGLED

Ideja na jednoj stranici

Tradicionalne poslovne aplikacije raspoređuju poslovno znanje kroz strukture baze, procedure, servise, korisnička sučelja, workflow mehanizme i integracijski kod. Takav pristup funkcionira, ali se s vremenom isto pravilo može pojaviti na više mjesta, pa svaka promjena zahvaća široku tehničku površinu.

Model-First arhitektura mijenja središte gravitacije. Upravljeni poslovni model postaje primarni artefakt. Baza podataka čuva i model i operativne podatke te ostaje odgovorna za deterministički integritet, transakcije, sigurnost i revizijsku sljedivost. AI interpretira namjeru korisnika i poslovni model, ali nije izvor istine.


Pet pomaka

- Poslovna promjena sve više postaje promjena modela
- AI postaje interpretator, a ne vlasnik
- Sučelje se generira, ali ostaje ujednačeno
- Audit povezuje značenje i dokaz
- Vrijednost se pomiče prema modelu, podacima i računalnoj snazi

KONTEKST

Zašto bi poslovnim sustavima mogla trebati nova paradigma

Današnje arhitekture nastale su u svijetu u kojem je računalu trebalo eksplicitno programirati gotovo svaki put interakcije.



Promjena nije samo manje slojeva - nego jedno jasno mjesto za poslovno značenje.

AI mijenja jednu važnu pretpostavku: tehnologija sve bolje može interpretirati namjeru, kontekst i strukturiranu semantiku. To ne uklanja potrebu za strogim pravilima. Otvara mogućnost da se trajno poslovno značenje izvuče iz ponavljanih implementacija u aplikacijama i smjesti u eksplicitni model koji različiti kanali mogu dosljedno interpretirati.

Problem nije u tome da su današnje arhitekture pogrešne. Problem je u tome što se mijenjaju neka ograničenja zbog kojih su takve arhitekture nastale.

TEMELJNA NAČELA

Što znači Model-First

- Upravljeni poslovni model jedini je izvor poslovnog značenja.
- Baza podataka konačni je izvor integriteta podataka, transakcija, autorizacije i determinističkog izvršenja.
- AI interpretira; ne posjeduje pravila i ne zaobilazi kontrole.
- Sučelja se mogu generirati prema namjeri i kontekstu, ali se prikazuju kroz stabilan dizajnerski sustav.
- Promjene modela verzioniraju se, odobravaju, testiraju i mogu se revidirati.
- Tehnologija je zamjenjiva. Poslovna semantika i podaci ostaju trajna imovina organizacije.



Entiteti

što postoji



Sposobnosti

što se može postići



Pravila

što mora biti istinito



Ovlasti

tko smije što



Tijek rada

kako se stanje mijenja



Interakcija

što korisnik treba razumjeti

REFERENTNA ARHITEKTURA

Model i podaci nalaze se unutar podatkovne platforme

Arhitektura namjerno izbjegava uvođenje novog srednjeg sloja poslovne logike koji bi ponovno postao mjesto dupliciranja pravila.



Model i podaci su u bazi; AI ih interpretira kroz dopuštene operacije.

Unutar platforme baze podataka zajedno postoje semantički model i operativni podatkovni model. Semantički model opisuje poslovno značenje. Operativne strukture čuvaju trajne činjenice. Ograničenja, autorizacija, transakcije, audit mehanizmi, funkcije i upravljane procedure provode ono što mora biti determinističko.

AI čita samo autorizirani dio modela, vodi korisnika i poziva isključivo eksplicitno dopuštene mogućnosti baze. Ne dobiva neograničeno pravo generirati vlastiti SQL nad produkcijskim podacima.

MODEL

Što opisuje upravljani model

POSLOVNO ZNAČENJE

Entiteti · odnosi · poslovni rječnik

UPRAVLJANO PONAŠANJE

Sposobnosti · pravila · ovlasti · tijek rada

SEMANTIKA INTERAKCIJE

Potrebni podaci · objašnjenja · namjera kanala

Namjera → dopuštena operacija → determinističko izvršenje → dokaz

Cilj nije spremati ekrane. Cilj je spremiti strojno interpretabilan opis poslovne namjere i ograničenja.

BAZA PODATAKA

Baza postaje više od spremišta

PLATFORMA BAZE PODATAKA

SEMANTIČKI MODEL

poslovno značenje, pravila, ovlasti, workflow, namjera interakcije

OPERATIVNI PODACI

entiteti, odnosi, stanja, trajne činjenice

KONTROLE I MOGUĆNOSTI BAZE

constraints · PL/SQL · transactions · security · audit

Baza ostaje relacijska ondje gdje je to najbolji prikaz trajnih poslovnih činjenica. Pojam kao što je Nalog 11 ne znači automatski da mora postojati fizička tablica NALOG_11. Fizičke strukture trebaju predstavljati stabilne entitete i odnose - naloge, stavke, račune, statuse, reference i odobrenja.

Integritet oko kojeg nema pregovora pripada determinističkim kontrolama baze: tipovima podataka, ograničenjima, referencijalnom integritetu, granicama transakcija, autorizaciji, nepromjenjivim audit zapisima te upravljanim funkcijama i procedurama.

Developeri razvijaju ponovljive mogućnosti baze umjesto novog tehničkog sloja za svaki zahtjev - primjerice validaciju, kontrolirani prijelaz stanja, spremanje, audit i odobrene integracijske operacije.

UMJETNA INTELIGENCIJA

Interpretator, a ne autoritet



Sigurnosna granica: privatni / suvereni cloud ili lokalno; najmanje potrebne ovlasti; kontrolirani izlaz; bez neograničenog SQL pristupa produkciji.

AI je prilagodljivi sloj između ljudske namjere i formalnog sustava. Može voditi razgovor, prepoznati što nedostaje, objasniti pravilo, sastaviti autorizirani zahtjev i odabrati prikladan način prikaza.


AI ne bi smio imati neograničeni SQL pristup niti postati konačni autoritet za računovodstveni, regulatorni ili podatkovni integritet. Probabilistička interpretacija može pomoći korisniku; determinističke kontrole baze provode ono oko čega nema pregovora.

AI sloj može biti u privatnom cloudu, suverenom cloudu ili lokalnoj infrastrukturi. Arhitektonski zahtjev je izolacija, najmanje potrebne ovlasti, kontrolirano izlaganje podataka i zamjenjivost - a ne ovisnost o jednom dobavljaču.

KORISNIČKO ISKUSTVO

Generirano, ali namjerno ujednačeno

Korisnik ne bi smio dobivati novi vizualni jezik svaki put kada AI generira sučelje.



Model opisuje potrebne podatke, dopuštene radnje i namjeru interakcije. Fiksni korporativni dizajnerski sustav daje provjerene komponente - forme, tablice, odobrenja, upozorenja, vremenske crte, nadzorne ploče i obrasce potvrde. AI ih slaže prema zadatku i ulozi; ne izmišlja novi dizajn pri svakoj interakciji.

Rezultat je prilagodljiv, ali ne kaotičan: sadržaj se mijenja s kontekstom, dok raspored i obrasci interakcije ostaju poznati.

OPERATIVNI MODEL

Kako se mijenjaju uloge

**Arhitekt podataka / modela**

semantika, pravila, strukture, verzioniranje

**Developer / inženjer baze**

ponovljive DB mogućnosti, integracije, sigurnost, performanse

**Poslovni korisnik**

validira stvarni način rada i ishode

**AI**

predlaže, objašnjava i interpretira - nije izvor istine

Najveća promjena nije nestanak inženjerstva, nego smanjenje ponavlanog implementacijskog rada.

Arhitekti podataka i modela vlasnici su formalne semantike, podatkovnih struktura i definicije upravljanih poslovnih pravila. Developeri i inženjeri baze implementiraju ponovljive determinističke mogućnosti, PL/SQL gdje je prikladno, integracije, performanse, sigurnost, alate, migracije i razvoj platforme. Poslovni korisnici potvrđuju predstavlja li model stvarni način rada.

AI može generirati kod, testove i prijedloge, ali promjene visokog utjecaja ostaju upravljane, pregledane i sljedive.

UPRAVLJANJE

Revizijska sljedivost i usklađenost po dizajnu



Od poslovnog značenja do tehničkog dokaza.


Svaka važna radnja treba biti rekonstruirana. Dokaz mora pokazati tko ju je pokrenuo, koja je verzija modela vrijedila, koja su pravila provjerena, koja je upravljana mogućnost izvršena, što se promijenilo i kakav je rezultat nastao.

Audit trag nije samo tehnički log. On povezuje poslovno značenje s determinističkim dokazom izvršenja.

AI može taj dokaz objasniti prirodnim jezikom, ali temeljni zapis mora ostati nepromjenjiv, deterministički i neovisno provjerljiv.

STUDIJA SLUČAJA

DEPRO 2030 - radni dan počinje namjerom, a ne izbornikom



DEPRO se koristi kao primjer iskustva Model-First sustava, bez pretvaranja arhitekture u rješenje specifično samo za DEPRO.

Korisnik počinje s obvezama i namjerom: stavke koje čekaju odobrenje, vraćene stavke, iznimke i rokovi. Razgovor, strukturirane forme, izvještaji i odobrenja dijele isti model i isti sigurnosni kontekst.

Sustav ne traži od korisnika da pamti gdje se funkcija nalazi. Korisnik izražava što želi postići; model određuje što je dopušteno i koji su podaci potrebni.

STUDIJA SLUČAJA

Nalog 11 kao operacija vođena modelom

AI podrška

Želim otvoriti Nalog 11.

Račun odobrenja nedostaje.

Koristi zadani račun.

U redu. Potrebno je dodatno odobrenje zbog iznosa.

Nalog 11

Broj naloga

2400-001

Debitni račun

SETTLEMENT-01

Kreditni račun

CONTROL-001

Iznos

125,000.00 EUR

Dodatno odobrenje potrebno

Pošalji na odobrenje


Forma nije primarni artefakt. Upravljeni model definira potrebne podatke, dopuštene vrijednosti, validacijska pravila, uvjete odobrenja i dopuštene operacije.

Korisnik može dati podatke razgovorom ili izravno kroz strukturirano radno sučelje. Oba načina rade nad istim kontekstom i istim determinističkim kontrolama.

Kada je korisnik spreman za slanje, AI poziva upravljanu mogućnost baze. Baza validira i izvršava. AI ne može zaobići pravilo koje nije zadovoljeno.

STUDIJA SLUČAJA

Regulatorna promjena bez ponovne izgradnje aplikacije



Jedna poslovna promjena - dvije različite površine promjene.


Pretpostavimo novu regulativu koja mijenja prag, uvodi dodatno odobrenje ili zahtijeva novi dokaz.

U zrelom Model-First sustavu primarna promjena radi se u upravljanoj modelu i, gdje je potrebno, u determinističkim kontrolama baze. Svi kanali interpretiraju istu objavljenu verziju modela.

Testiranje i dalje ostaje nužno. Mijenja se njegova površina: testiraju se ispravnost modela, izvršne kontrole, generirana interakcija, integracijski učinci i korisnička prihvatljivost - umjesto ponavljanog mijenjanja istog pravila u više aplikacijskih slojeva.

STUDIJA SLUČAJA

Kanal se mijenja. Poslovni model ostaje isti.



Iste ovlasti, pravila i audit - različita prezentacija prema kanalu.


Desktop, web, mobilno i glas postaju različiti izrazi iste upravljane semantike.

Količina prikazanih informacija i obrazac interakcije mogu se razlikovati prema uređaju i zadatku, dok ovlasti, pravila, životni ciklus i zahtjevi revizije ostaju jednaki.

Mobilni korisnik može odobriti stavku kroz sažeti tijek; kontrolor na desktopu može dobiti detaljnu tablicu; glasovna interakcija može tražiti potvrdu. Sva tri kanala koriste istu modeliranu sposobnost.

STUDIJA SLUČAJA

Audit Replay - rekonstrukcija jedne DEPRO odluke



Zašto je Nalog 11 bio dopušten? Sustav prikazuje poslovni razlog i dokaz izvršenja.

Povijesna transakcija trebala bi se moći reproducirati kao lanac dokaza, a ne samo pronaći kao zapis u logu.

Primjer: revizor odabire Nalog 11 iz ranijeg razdoblja i vidi korisnika koji je pokrenuo radnju, namjeru koju je AI interpretirao, aktivnu verziju modela, točno pravilo koje je vrijedilo, rezultat validacije u bazi, odobrenja, promjene stanja i konačni ishod.

Razlika u odnosu na opće načelo audita je praktična: može se rekonstruirati zašto je baš ta transakcija bila dopuštena ili odbijena, poslovnim jezikom, uz nepromjenjive tehničke dokaze.

UVOĐENJE


Evolucijski put, a ne nagla zamjena



1. Formalizirati postojeću domenu bez promjene korisničkog iskustva.
2. Uvesti AI kao ograničenog asistenta iznad postojećih sustava.
3. Pilotirati jedan jasno ograničen proces kao pravi Model-First primjer.
4. Mjeriti prihvaćenost korisnika, revizijsku sljedivost, vrijeme promjene, greške, stabilnost i ukupni trošak.
5. Širiti pristup samo ondje gdje dokazi pokazuju da je jednostavniji, sigurniji i lakši za promjenu.

STRATEŠKE POSLJEDICE

Gdje bi se vrijednost mogla premjestiti



Kombinacija je važnija od bilo koje pojedinačne komponente.

Ako se više poslovnih promjena može izraziti kroz upravljani model umjesto kroz razvoj posebnog aplikacijskog koda, granični trošak prilagodbe softvera može pasti.

Istodobno se vrijednost premješta prema trima trajnim resursima: kvaliteti poslovnog modela, kvaliteti i upravljanju podacima te sigurnom računalnom kapacitetu.

To je preraspodjela, a ne obećanje da IT postaje jeftin. Manje ponavljanog aplikacijskog koda može istodobno značiti veće ulaganje u podatkovnu arhitekturu, AI sposobnosti, sigurnost i računalnu infrastrukturu.

Zašto računalni kapacitet postaje strateškiji

>2x

Projicirani rast globalne potrošnje električne energije podatkovnih centara do 2030. (IEA osnovni scenarij).

Vanjski kontekst

IEA projicira približno 945 TWh globalne potrošnje električne energije podatkovnih centara do 2030., uz AI kao najveći pokretač rasta.

AI čini ekonomski korisnima mnoge nove oblike obrade: stalnu interakciju, dohvat podataka, simulacije, validacije, analitiku i privatnu inferenciju. Čak i kada hardver postaje učinkovitiji po jedinici performansi, ukupna potražnja može rasti jer raste broj i intenzitet AI opterećenja.

IEA projicira da će globalna potrošnja električne energije podatkovnih centara do 2030. više nego udvostručiti, pri čemu je AI najveći pokretač rasta. To ne dokazuje da svaka organizacija treba vlastiti podatkovni centar, ali pokazuje da računalna snaga, energija i planiranje kapaciteta postaju strukturna strateška pitanja. [1]

Za Model-First sustave to je važno jer poslovni model vrijedi samo ako ga organizacija može interpretirati sigurno, pouzdano i u potrebnom opsegu.

INFRASTRUKTURNA STRATEGIJA

Izgraditi, unajmiti ili kombinirati

CLOUD / NAJAM	VLASTITO / IZGRADNJA	HIBRIDNO
• Elastičan kapacitet • Brz pristup novim AI servisima • Niže početno ulaganje • Veća ovisnost o pružatelju	• Kontrola i suverenost • Predvidljiv kapacitet • Moguća ekonomika pri visokoj iskorištenosti • Kapital i operativna složenost	• Privatna baza + elastični vrhovi • Raspored prema osjetljivosti • Postupno širenje • Zahtijeva snažnu arhitektonsku disciplinu


Cloud / najam: najjači kada su najvažniji elastičnost, brzina uvođenja i pristup brzo promjenjivim AI servisima.

Vlastito / izgradnja: najjače kada su opterećenja trajna, osjetljiva, predvidiva i strateški kritična te kada organizacija može učinkovito upravljati infrastrukturom.

Hibridno: najjače kada se stabilna privatna baza može kombinirati s vanjskom elastičnošću i specijaliziranim uslugama.

Ispravan odgovor ovisi o konkretnom opterećenju. Cilj je zadržati opcionalnost: izbjeći prerano preinvestiranje, ali i ovisnosti koje se kasnije teško ili skupo mijenjaju.

Kada razmotriti veću kontrolu nad infrastrukturom?



Argument za veću kontrolu postaje snažniji kada se spoje tri uvjeta: trajno visoka iskorištenost, visoka osjetljivost ili zahtjevi suverenosti te kritičnost za svakodnevno poslovanje.

Za veliku europsku grupu praktičan korak nije unaprijed proglasiti “gradimo podatkovni centar” univerzalnim odgovorom. Potrebno je već sada izraditi višegodišnje scenarije potražnje - rast AI inferencije, energija i hlađenje, sigurnost, otpornost, ciklusi zamjene akceleratora, stručni kadar, suverenost i trošak izlaska iz vanjskih usluga - kako bi se odluke donijele prije nego što kapacitet postane usko grlo.

Taj smjer odgovara i širem europskom fokusu na suverene AI i cloud kapacitete. Europska komisija je u lipnju 2026. predložila Cloud and AI Development Act s ciljem snažnog širenja europskih kapaciteta podatkovnih centara. [2][3]

EKONOMSKA HIPOTEZA

Jeftinija prilagodba, vrjednija infrastruktura



Model-First teza sugerira preraspodjelu troška i vrijednosti, a ne jednostavno smanjenje troškova.

Vrijednost softvera pomiče se s količine prilagođenog koda prema kvaliteti formalne poslovne semantike. Inženjerski rad pomiče se s jednokratnih funkcionalnosti prema ponovljivim mogućnostima baze, sigurnosti, integracijama i kvaliteti platforme. Planiranje infrastrukture postaje strateškije kako AI upotreba postaje stalna i ugrađena u svakodnevni rad.

Snažna dugoročna pozicija mogla bi biti svjesna kombinacija vlastitih sposobnosti i vanjske elastičnosti, a ne ideološka vezanost isključivo uz cloud ili lokalnu infrastrukturu.

ZAŠTITNA NAČELA

Što se ne mijenja

- Odgovornost ostaje na organizaciji i ovlaštenim ljudima.
- Sigurnost, razdvajanje dužnosti i regulatorne kontrole ostaju obvezni.
- Kritična pravila integriteta ostaju deterministička.
- Kvaliteta, porijeklo i zadržavanje podataka ostaju temeljni.
- Korisnicima i dalje trebaju stabilna, predvidljiva i pristupačna iskustva.
- Testiranje ostaje nužno - ali sve više testira model, izvršne kontrole i interpretaciju, a manje dupliciranu aplikacijsku logiku.

ZAŠTITNA NAČELA

Što ova arhitektura nije


- Nije neograničeni AI pristup produkcijskim tablicama.
- Nije tvrdnja da prirodni jezik treba zamijeniti svako vizualno sučelje.
- Nije tvrdnja da baza sama rješava svaki problem distribuiranih sustava ili integracija.
- Nije tvrdnja da developeri ili inženjerska disciplina postaju nepotrebni.
- Nije zahtjev da svaka organizacija izgradi vlastiti podatkovni centar.
- Prijedlog je da trajno poslovno značenje postane eksplicitno, upravljano i ponovno iskoristivo kroz različite tehnologije.

Otvorena pitanja koja treba testirati, a ne ignorirati

- Kako uskladiti čitljivost jezika modeliranja ljudima s preciznošću potrebnom stroju?
- Koja pravila pripadaju semantičkim metapodacima, a koja uvijek moraju ostati determinističke kontrole baze?
- Kako odobravati, testirati, certificirati i vraćati verzije modela?
- Kako interpretaciju AI-a učiniti dovoljno ponovljivom za procese visokog rizika?
- Kako generirano sučelje ograničiti dizajnerskim sustavom i standardima pristupačnosti?
- Kako mjeriti odnos između nižeg troška prilagodbe softvera i veće potrošnje računalnih resursa?
- Koja opterećenja opravdavaju stratešku kontrolu infrastrukture, a koja trebaju ostati elastična i vanjska?

VIZIJA 2035

Tehnologije će se mijenjati. Upravljeni poslovni model treba ostati.



Model ostaje. Tehnologije se mijenjaju. Interpretacija se prilagođava.

Trajna imovina je eksplicitno razumijevanje organizacije o tome kako njezino poslovanje funkcionira: semantika, pravila, ovlasti, procesi i podaci.

Ako je to razumijevanje dovoljno precizno da ga ljudi mogu upravljati i dovoljno strukturirano da ga strojevi mogu interpretirati, poslovni sustavi mogu postati manje usmjereni na stalno programiranje aplikacija, a više na kontinuirano modeliranje poslovanja.

AI model, korisnički kanali i infrastruktura mogu se mijenjati. Poslovni model ostaje trajno središte.

Pitanje koje vrijedi postaviti

Kada bismo danas od nule projektirali poslovne sustave - s modernim bazama podataka, upravljanim podacima i AI-em koji može interpretirati strukturiranu semantiku - bismo li ih doista gradili potpuno jednako kao prije dvadeset godina?

Možda sljedeću generaciju poslovnog softvera neće definirati količina koda koju možemo generirati, nego preciznost kojom možemo modelirati poslovanje.

Modeliraj jednom. Upravljaј eksplicitno. Interpretiraj svugdje.

IZVORI

Odabrani vanjski kontekst

[1] International Energy Agency (IEA), Energy and AI, 2025. Izvješće projicira da će globalna potrošnja električne energije podatkovnih centara do 2030. više nego udvostručiti na približno 945 TWh, uz AI kao najveći pokretač rasta.

[2] Europska komisija, Cloud and AI Development Act, prijedlog objavljen u lipnju 2026. Inicijativa je usmjerena na jačanje europskih cloud i AI kapaciteta te značajno povećanje kapaciteta podatkovnih centara.

[3] Europska komisija, Strengthening Europe's Tech Sovereignty, 2026. Politika naglašava sposobnost Europe da razvija i kontrolira ključne tehnologije, podatke i infrastrukturu.

[4] OECD, Competition in Artificial Intelligence Infrastructure, 2025. Izvješće opisuje napredne čipove, podatkovne centre, energiju, hlađenje i mrežu kao temeljne fizičke ulaze AI infrastrukture.

Ovi izvori daju vanjski kontekst infrastrukturnom poglavlju. Sama Model-First arhitektura autorski je konceptualni prijedlog koji treba potvrditi ograničenim pilotima i empirijskim mjerenjem.